

Practical Assignment – Machine Learning

Mazilu Cosmin-Alexandru
Mardare Andrei Daniel

January 16, 2026

1 Problemă & Dataset

Datele provin din bonuri fiscale; fiecare linie reprezintă un produs dintr-un bon. Interval: 2025-09-05 – 2025-12-03, ~7,869 bonuri, 28,039 linii, 59 produse unice. Coș mediu: 3.56 produse/bon (max 26). Lista sosuri standalone: Crazy, Cheddar, Extra Cheddar, Garlic, Tomato, Blueberry, Spicy, Pink.

2 Preprocesare

Conversie `data_bon` la `datetime`; derivare `day_of_week` (1–7), `hour_of_day`, `is_weekend`.

Agregări pe bon: `cart_size`, `distinct_products`, `total_value`.

Vector produse: număr de apariții per produs (`binary_counts` optional). Pentru modele de sos, coloana sosului curent se elimină (evităm scurgeri).

Interacțiuni optionale: (Crazy Schnitzel, French fries/Baked potatoes/Aqua Carpatica).

Split pe bonuri: bonurile au fost despărțite în ordine temporală: primele 80% din bonuri au fost folosite pentru antrenare și restul de 20% au fost folosite pentru testare.

Ranking: se construiesc coșuri parțiale eliminând aleator un produs eligibil; prețul mediu per produs folosit în scor.

3 Modele

Regresie Logistică (custom GD) Implementare proprie cu standardizare internă, gradient descent batch, oprire la toleranță, L2 optional. Folosește doar `numpy`.

Regresie Logistică (sklearn) Pipeline `StandardScaler` + `LogisticRegression` pentru referință.

Per-sauce (2.2) Un model logistic per sos; metricile se calculează pe test; recomandarea Top-K ordonează sosurile după probabilități prezise, comparat cu baseline de popularitate.

Ranking upsell Bernoulli Naive Bayes (custom) pe prezență de produse; scorul final: $score(p | cos) = P(p | cos) \cdot price(p)$. Baseline: popularitate globală și venit global (contor \times preț).




Figure 1: Matricea de confuzie și Curba ROC pentru predicția Crazy Sauce

4 Rezultate

4.1 2.1 Crazy Sauce (cosă conține Crazy Schnitzel, split temporal 80/20)

Model	Acc	Prec	Rec	F1	ROC-AUC
Majority (tot timpul 1)	0.476	0.476	1.000	0.645	0.500
LogReg sklearn	0.933	0.906	0.959	0.931	0.962
LogReg custom GD	0.938	0.925	0.947	0.936	0.967

Matrice confuzie (custom GD): $\begin{bmatrix} 174 & 13 \\ 9 & 161 \end{bmatrix}$ (TN, FP / FN, TP).

Coefficienți majori (custom GD): pozitivi — cart_size, distinct_products, total_value, Baked potatoes, băuturi cola; negativi — alte sosuri standalone (Cheddar, Garlic, Blueberry, Tomato, Spicy, Pink) și produse deja cu sos (Crazy Fries cu Cheddar).

4.2 2.2 Per-sauce + recomandare (split temporal 80/20, Top-3)

Sos	Acc	Prec	Rec	ROC-AUC
Crazy Sauce	0.681	0.334	0.759	0.751
Cheddar Sauce	0.867	0.653	0.142	0.760
Extra Cheddar Sauce	0.996	0.000	0.000	0.956
Garlic Sauce	0.895	0.375	0.097	0.760
Tomato Sauce	0.974	1.000	0.024	0.809
Blueberry Sauce	0.673	0.130	0.409	0.706
Spicy Sauce	0.811	0.110	0.397	0.739
Pink Sauce	0.974	0.167	0.061	0.807

Recomandare Top-3 (baskets cu sos în test, $n = 829$): Hit@3 = 0.744 vs baseline popularitate 0.726; Precision@3 = 0.270 vs 0.268.

4.3 Ranking upsell (cosă parțial, min 20 apariții produs, split temporal 80/20)

K	Model	Hit@K	Popularitate	Hit@K	Venit	Hit@K
1		0.225		0.093		0.109
3		0.387		0.217		0.182
5		0.468		0.320		0.275




Figure 2: Curbe ROC comparative pentru modelele per-sos

Evaluat pe 1,518 coșuri parțiale. Modelul NB + preț depășește consistent bazele.

5 Concluzii & îmbunătățiri

Modelul logistic custom atinge performanța sklearn; principalele semnale sunt dimensiunea/varietatea coșului și substituția între sosuri.

Recomandarea per-sos depășește popularitatea, dar sosurile rare (Extra Cheddar, Pink) au recall mic; ar ajuta undersampling/oversampling sau modele ierarhice.

Ranking NB + preț bate popularitatea/venitul, dar poate fi rafinat cu modele secvențiale (item2vec), factorization machines, sau calibrare mai bună a probabilităților.

Grafică potențială: ROC-uri per sos, matrice de confuzie pentru 2.1, curbe Hit@K; pot fi generate din codul existent pentru completarea raportului.




Figure 3: Performanță Hit@K pentru modelul de ranking vs baseline